

FACULTAD DE MATEMÁTICA Y
COMPUTACIÓN UNIVERSIDAD DE LA
HABANA

TESIS DE DIPLOMA DE LA ESPECIALIDAD CIENCIA
DE LA COMPUTACIÓN

**Segmentación de Úlceras de Pie
Diabético (UPD) en secuencias
de imágenes RGB mediante el
Segment Anything Model
(SAM).**

Autor: Abdel Fregel Hernández
Tutor: Dr. José Alejandro Mesejo Chiong

La Habana
27 de diciembre de 2024

1. Agradecimientos

2. Resumen

3. Índice

Índice

1. Agradecimientos	I
2. Resumen	II
3. Índice	III
4. Introducción	1
4.1. Objetivos	3
4.2. Estructura de la tesis	4
5. Capítulo 1	5
5.1. Segmentación de Úlceras del Pie Diabético: Definición	5
5.2. Revisión Bibliográfica	6
5.3. Métodos Basados en Deep Learning	7
5.4. Datasets Existentes	7
6. Capítulo 2	8
6.1. Modelos de Base(Foundation Models)	8
6.2. Segment Anything Model(SAM)	8
6.3. Adaptando SAM para imágenes médicas.	11
7. Conclusiones	14
8. Recomendaciones	15
9. Bibliografía	16
10. Anexos	19

4. Introducción

La diabetes(diabetes mellitus), es una enfermedad crónica que afecta la forma en la que el cuerpo utiliza la glucosa, una fuente clave de energía. De acuerdo a la *Federación Internacional de Diabetes*, en el año 2021 se reportaron 6.7 millones de muertes a causa de esta enfermedad [10]. En nuestro país, según el *Anuario Estadístico de Salud 2022* [22], la prevalencia es de 66,50% de enfermos por cada 1000 habitantes.

Cerca del 86% de personas que padecen de diabetes sufren de úlcera de pie diabético ¹(UPD), y corren el riesgo de amputación. La cicatrización de estas úlceras puede tardar semanas, meses e incluso años, deteriorando la calidad de vida de los pacientes. Actualmente, los médicos cubanos especializados en el tema no cuentan con una herramienta cuantitativa efectiva que valore la severidad y el proceso de curación de las UPD. La medición regular de las úlceras es crucial para evaluar la efectividad del tratamiento y realizar ajustes cuando sea necesario. Un seguimiento adecuado puede prevenir la progresión de la úlcera y reducir el riesgo de amputaciones.

Existen métodos de segmentación y medición de heridas que han conseguido grandes avances en esta área. La calidad de estas es esencial para varios análisis de heridas, como por ejemplo la clasificación de tejidos, Reconstrucción 3D, y la evaluación de la cicatrización[12]. Se pueden clasificar en dos tipos: aquellos que requieren contacto y los que no. Los métodos de contacto son invasivos y presentan un alto margen de error; por ello, este trabajo se centra en los métodos no invasivos.

Varios estudios han abordado esta problemática. Por ejemplo, en Filko et al. [12] hacen uso de un sofisticado brazo robótico de 7 grados de libertad(DoF), equipado con una cámara RGB-D ² y un escáner 3D de alta precisión, para la segmentación y medición de heridas. Este artículo aporta un nuevo algoritmo de segmentación que utiliza una combinación de procedimientos 2D y 3D para segmentar correctamente un modelo de herida en 3D.

¹Hace referencia a una complicación grave de la diabetes que se manifiesta como una herida o llaga abierta en el pie

²RGB-D, se refiere a una camara capaz de captar imágenes a color(RGB, formato Red(rojo),Green(verde),Blue(azul) y un sensor de profundidad (D(depth),por su sigla en inglés)

La segmentación se realiza a partir de múltiples fotografías 2D por herida, impulsada por una red neuronal profunda en forma del clasificador MobileNetV2 [12]. Este clasificador se combina óptimamente con un único modelo 3D y la inicialización del contorno de la herida. Este contorno inicial se optimiza y ajusta mediante un modelo de contorno activo [12], que envuelve estrechamente la superficie real de la herida utilizando la curvatura de la superficie para alcanzar su objetivo.

En otro estudio realizado por Filko et al. [11] se exploró la medición y reconstrucción de heridas crónicas de lenta curación, utilizando cámara RGB-D. Con la llegada de cámaras RGB-D económicas, la comunidad de visión por computadora ha ganado una forma más accesible para innovar y crear aplicaciones en diversos campos, incluyendo la medicina, [11]. Estas cámaras, que combinan información de color y profundidad, permiten un análisis más detallado y preciso de imágenes, facilitando el desarrollo de tecnologías que mejoran diagnósticos y tratamientos. El sistema desarrollado en dicho artículo detecta automáticamente heridas analizando bloques de imagen según la similitud del histograma de color utilizando un enfoque de vecinos más cercanos(KNN,por sus siglas en inglés). Este método permite identificar características específicas de las heridas en imágenes, facilitando su segmentación y medición.

Es fundamental el desarrollo de una herramienta capaz de realizar la segmentación y la medición de estas heridas lo más preciso posible, por lo que en este trabajo se propone , para la tarea de segmentar las imágenes, utilizar una herramienta desarrollada por Meta AI llamada Segment Anything Model(SAM)[20] que permite identificar y segmentar objetos en imágenes de manera eficiente. Esta herramienta ha ganado popularidad en cuanto a las tareas de segmentación y en el presente trabajo será usada para hacer una segmentación de las imágenes de UPD, las cuales serán tomadas con una cámara RGB-D para asegurar su calidad.

La cámara que se utiliza es una cámara Intel Realsense D435i RGB-D. La cámara utiliza luz estructurada infrarroja y métodos binoculares para obtener información de profundidad, que es la tecnología más común y madura utilizada en las cámaras RGB-D de grado consumidor actuales. La cámara de profundidad puede emitir un flujo de video de hasta 720p a 90 FPS, y la cámara RGB puede emitir un flujo de video de hasta 1080p a 30 FPS [28].

Luego de la segmentación se realizará una clasificación de los tejidos para poder realizar una evaluación de la cicatrización.

La importancia de los tejidos en el proceso de cicatrización radica en que cada tipo de tejido desempeña un papel crucial en la reparación y regeneración de la herida. Durante la cicatrización, se forman diferentes tipos de tejidos, siendo el tejido de granulación uno de los más fundamentales [23]. Este tejido no solo es esencial para el cierre de la herida, sino que también prepara el lecho para la epitelización, proporcionando un entorno adecuado para la migración celular y la formación de nuevos vasos sanguíneos.

Sin embargo, la presencia de tejido necrótico y biofilm bacteriano puede complicar este proceso. El tejido necrótico, formado por células muertas y detritos, actúa como una barrera que impide la formación de tejido de granulación saludable [7]. Esto no solo retrasa el proceso de curación, sino que también aumenta el riesgo de infección, lo que puede llevar a complicaciones graves, como la amputación. Por lo tanto, es crucial realizar un desbridamiento adecuado para remover el tejido necrótico y permitir que la herida progrese hacia las fases de proliferación y cicatrización. Por otro lado, el biofilm bacteriano se forma cuando microorganismos se adhieren a la superficie del lecho de la herida, creando microcolonias protegidas por una matriz polimérica. Esta estructura no solo protege a las bacterias de los tratamientos antibióticos convencionales, sino que también interfiere con la respuesta inmune del cuerpo y dificulta la migración celular necesaria para regenerar tejido sano. La identificación y tratamiento adecuados del tejido necrótico y el biofilm son esenciales para facilitar una curación efectiva y mejorar la calidad de vida del paciente.

4.1. Objetivos

Este trabajo tiene como objetivo desarrollar una herramienta que permita realizar la segmentación automática de úlceras y los tejidos que las componen a partir de una secuencia de imágenes RGB-D, facilitando así el tratamiento por parte del médico.

Para lograr este objetivo general se tiene los siguientes objetivos específicos:

1. Hacer un estudio de la literatura sobre los métodos de segmentación

2. Estudiar sobre la utilización del Segment Anything Model.
3. La creación de un dataset para la posterior evaluación del modelo
4. La evaluación del modelo en cuanto métricas de calidad.

4.2. Estructura de la tesis

La tesis está organizada en cuatro capítulos. El Capítulo 1 presenta una revisión literaria donde se discuten algunos algoritmos existentes así como datasets relevantes. El Capítulo 2 ofrece una introducción al SAM y su aplicación en imágenes médicas. En el Capítulo 3 se explican los detalles estructurales e implementativos del sistema propuesto. Finalmente, el Capítulo 4 muestra los resultados obtenidos y compara estos con otros modelos existentes utilizando medidas cualitativas. Se concluirá con recomendaciones basadas en esta investigación para futuras continuaciones del trabajo. Esta versión busca mantener un hilo conductor claro entre las ideas expuestas, eliminando saltos innecesarios y mejorando la cohesión general del texto.

5. Capítulo 1

5.1. Segmentación de Úlceras del Pie Diabético: Definición

La segmentación de úlceras del pie diabético (UPD) es un proceso crítico en el manejo y tratamiento de esta complicación común en pacientes diabéticos. Se refiere a la identificación y delineación automática de las regiones afectadas en imágenes médicas, lo que permite a los profesionales de la salud evaluar con precisión el tamaño y la gravedad de las úlceras. Estas lesiones son abiertas y pueden surgir debido a una combinación de factores como neuropatía, que reduce la sensibilidad en los pies, isquemia, que limita el flujo sanguíneo necesario para la curación, y presión prolongada sobre áreas específicas del pie debido a deformidades o calzado inadecuado.

La segmentación es crucial no solo para el diagnóstico inicial, sino también para el seguimiento del proceso de curación. Al segmentar correctamente las úlceras, se puede monitorear su evolución y responder adecuadamente a los cambios en el estado del paciente. Esto es particularmente importante dado que las úlceras del pie diabético pueden llevar a infecciones severas y, en casos extremos, a amputaciones. La capacidad para segmentar estas lesiones con precisión puede mejorar significativamente la calidad de vida de los pacientes al permitir una intervención temprana y adecuada en el manejo de las úlceras [4].

Además, la segmentación automática ha sido objeto de investigación reciente, donde se han explorado diferentes métodos para mejorar su efectividad. Por ejemplo, estudios han demostrado que el uso de algoritmos avanzados puede facilitar la identificación precisa de los bordes de las úlceras, lo que es fundamental para determinar el área afectada y planificar tratamientos adecuados [2]. La implementación de técnicas como la Transformada Wavelet Discreta Logarítmica ha mostrado resultados prometedores al mejorar la calidad visual de las imágenes antes de aplicar algoritmos de segmentación [3].

5.2. Revisión Bibliográfica

En la literatura científica, se han utilizado diversos métodos para la segmentación de úlceras del pie diabético (UPD). Tradicionalmente, los enfoques manuales o semiautomáticos han sido comunes, donde los especialistas marcan las áreas afectadas en las imágenes. Sin embargo, estos métodos son propensos a errores humanos y requieren mucho tiempo, lo que puede afectar la eficiencia del diagnóstico y el tratamiento [3]. En Cuba, por ejemplo, se ha documentado que la evaluación de estas lesiones se realiza manualmente, lo que limita la capacidad de respuesta ante cambios en el estado de las úlceras [3].

Con el avance de la tecnología, se han desarrollado métodos automáticos que utilizan algoritmos matemáticos y técnicas de procesamiento de imágenes. Entre estos se encuentran el método Chan-Vese, el modelo de mezclas gaussianas y GrabCut, que han demostrado ser efectivos en diversas condiciones [2]. En un estudio descriptivo realizado en pacientes diabéticos, se utilizó el marco estereotáxico FrameHeber03® para obtener imágenes planimétricas estandarizadas de las úlceras y se aplicaron diferentes técnicas de segmentación. Los resultados mostraron que el método de mezclas gaussianas era el más factible y preciso para segmentar las lesiones, especialmente en pacientes con piel oscura, donde se observa un mayor contraste entre la piel y el borde de la úlcera [3].

Recientemente, se ha incrementado el uso de técnicas basadas en aprendizaje profundo, como las redes neuronales convolucionales (CNN), que han mostrado resultados prometedores al aprender características complejas directamente desde los datos sin necesidad de preprocesamiento extenso [1]. Estas técnicas no solo automatizan el proceso de segmentación, sino que también mejoran significativamente la precisión en comparación con los métodos tradicionales. Por ejemplo, un estudio reciente reportó un coeficiente de similitud Dice superior a 0.794 para la segmentación automática de UPD utilizando modelos de redes neuronales convolucionales completas (FCNs) [1].

La implementación de estos métodos automáticos no solo facilita una evaluación más rápida y precisa del estado de las úlceras del pie diabético, sino que también permite a los profesionales médicos tomar decisiones informadas sobre el tratamiento y seguimiento del paciente. La combinación de técnicas tradicionales con nuevas tecnologías representa un avance significativo en el manejo clínico de esta complicación diabética.

5.3. Métodos Basados en Deep Learning

Los métodos basados en deep learning han revolucionado la segmentación médica, incluyendo la segmentación de UPD. Las redes neuronales convolucionales (CNN) son particularmente efectivas debido a su capacidad para aprender representaciones jerárquicas a partir de grandes conjuntos de datos. Modelos como U-Net y Fully Convolutional Networks (FCNs) han sido ampliamente utilizados para este propósito [9]. Estos modelos no solo permiten una segmentación precisa, sino que también pueden manejar variaciones en las imágenes causadas por diferentes condiciones de iluminación o tipos de piel [5]. La implementación de estos métodos ha demostrado mejorar significativamente las métricas de evaluación como el coeficiente Dice y la intersección sobre unión (IoU), lo que indica un avance considerable respecto a los métodos tradicionales.

La calidad de la segmentación se evalúa utilizando diversas métricas que reflejan la precisión y efectividad del algoritmo aplicado. Entre las métricas más comunes se encuentran el coeficiente Dice, que mide la similitud entre la predicción del modelo y la verdad conocida; la intersección sobre unión (IoU), que evalúa la superposición entre las áreas predicha y real; así como la precisión y recall, que proporcionan información sobre los verdaderos positivos y negativos [8]. Estas métricas son esenciales para comparar diferentes enfoques y determinar cuál es más efectivo para segmentar úlceras del pie diabético bajo diversas condiciones.

5.4. Datasets Existentes

Existen varios datasets disponibles para entrenar y evaluar modelos destinados a la segmentación automática de UPD. Uno notable es el dataset propuesto por Wang et al., que contiene más de 700 imágenes con anotaciones detalladas sobre las regiones afectadas por úlceras [5]. Este dataset proporciona una regla de oro para evaluar los modelos entrenados, permitiendo comparaciones con otros enfoques existentes. Además, otros estudios han utilizado conjuntos más pequeños pero igualmente valiosos que permiten realizar análisis comparativos entre diferentes algoritmos [9]

6. Capítulo 2

6.1. Modelos de Base(Foundation Models)

Los modelos de base son un enfoque transformador en la inteligencia artificial (IA) que aprovecha grandes conjuntos de datos para realizar una variedad de tareas en diferentes dominios. Estos modelos se entrenan en datos extensos, generalizados y, a menudo, no etiquetados, lo que les permite adaptarse y ajustarse para aplicaciones específicas.

Uno de los modelos de base más conocidos es la serie GPT (Generative Pre-trained Transformer) [6, 24], que ha demostrado capacidades y rendimiento impresionantes en una variedad de tareas de procesamiento de lenguaje natural, como la finalización de oraciones, la respuesta a preguntas y la traducción de idiomas. Vea [29]. Los modelos fundamentales también han mostrado un fuerte potencial para resolver una amplia gama de tareas posteriores en el análisis de imágenes médicas y ayudar a acelerar el desarrollo de modelos precisos y robustos. [29].

6.2. Segment Anything Model(SAM)

SAM es el primer modelo fundamental para la segmentación general de imágenes. Ha logrado resultados impresionantes en diversas tareas de segmentación de imágenes naturales [15]. Sin embargo, la segmentación de imágenes médicas (MIS) es más desafiante debido a las complejas modalidades, las finas estructuras anatómicas, los contornos de objetos inciertos y complejos, y la amplia variedad de escalas de objetos. Se basa en el modelo Vision Transformer (ViT) y fue entrenado en un gran conjunto de datos que contiene 11 millones de imágenes con 1 mil millones de máscaras.


SAM utiliza una arquitectura transformer-based, a la cual se le ha probado su eficiencia en el procesamiento de lenguaje natural y en tareas de reconocimiento de imágenes. Específicamente, SAM contiene un codificador de imagen(image encoder) basado en un Vision Transformer(ViT), con este extrae las características de la imagen, también utiliza un prompt encoder para integrar las interacciones del usuario y por último un mask decoder con el objetivo de predecir las máscaras de segmentación con la fusión de las características de la imagen con las entradas del usuario.

En la figura 1 se aprecia la estructura de SAM:

- 1 Image Encoder: SAM utiliza un image encoder basado en un Vision Transformer preentrenado en el esquema de Masked Autoencoder(MAE), el cual esta adaptado para procesar imágenes de alta resolución. Este toma imágenes de 1024 x 1024 y da como salida image embeddings bajando su tamaño a un mapa de características de 64 x 64. Vea [29]
- 2 Prompt Encoder: para esto dos tipos de ellos son considerados, uno incluyendo puntos y rectángulos y otro que trabaja con máscaras. Vea [29]
- 3 Mask Decoder : consiste en dos transformer layers con una máscara de predicción dinámica y una puntuación de regresión Intersection-over-Union(IoU, por sus siglas en inglés). Vea [29]

Durante el entrenamiento, la predicción de salida se supervisa con la combinación lineal de la pérdida focal [17] y la pérdida de Dice [21] , y se entrena para la tarea de segmentación mediante prompts geométricos mixtos.

Figura 1: Imagen adaptada de [29]



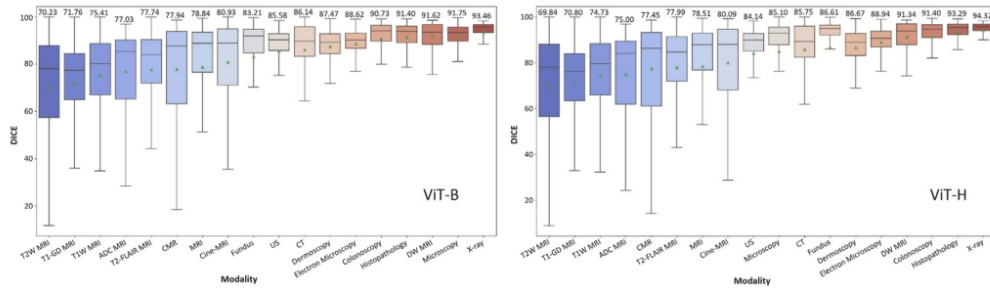
Aún cuando es evidente el potencial de SAM para la segmentación de imágenes naturales, presenta limitaciones en el ámbito de las imágenes médicas. El rendimiento limitado de SAM en imágenes médicas se atribuye a su insuficiente comprensión de desafíos específicos del ámbito médico [19], como el bajo contraste de imagen, los contornos de tejidos ambiguos y las pequeñas regiones de lesiones. Estos factores complican el proceso de segmentación en

comparación con las imágenes naturales.

El enfoque más avanzado para mejorar SAM para aplicaciones médicas implica realizar un ajuste completo del modelo en conjuntos de datos médicos. Sin embargo, este método es costoso en términos computacionales y requiere una cantidad significativa de recursos de memoria, lo que plantea dudas sobre su necesidad, dado que estudios previos han demostrado que los modelos visuales preentrenados suelen mostrar una fuerte transferibilidad a imágenes médicas [25].

En Zhang et al. [29] realizan una evaluación de SAM centrándose en una amplia gama de objetivos anatómicos y patológicos a través de diferentes modalidades de imagen médica. Estas modalidades abarcan tanto imágenes médicas en 2D (por ejemplo, radiografías, patología, ultrasonido, endoscopia y colonoscopia) como imágenes médicas en 3D (por ejemplo, Tomografía Computarizada (TC), Resonancia Magnética (RM) y Tomografía por Emisión de Positrones (PET)). Presentan el uso en cero disparos de SAM en la segmentación de imágenes médicas, organizado según los formatos de las modalidades de imagen médica.

Figura 2: Resultados cuantitativos de segmentación del modelo SAM en 18 modalidades de imagen diferentes en un estudio empírico a gran escala [15]. Imagen adaptada de [29]



En general, SAM requiere una interacción humana sustancial para lograr un rendimiento de segmentación moderado, lo que solo requiere unos pocos puntos o indicaciones de caja delimitadora. Los resultados de la evaluación en varios conjuntos de datos indican la limitada capacidad de generalización de SAM cuando se aplica directamente a la segmentación de imágenes médicas, que varía significativamente entre diferentes conjuntos de datos y tareas. Si bien SAM demuestra un rendimiento notable comparable a los métodos

SOTA³ en la identificación de objetos bien definidos en ciertas modalidades de imagen, presenta imperfecciones o fracasos totales en situaciones más desafiantes. Esto es particularmente evidente al tratar con objetivos de segmentación que presentan bordes débiles, bajo contraste, pequeño tamaño y formas irregulares, alineándose con los hallazgos de otras investigaciones. Para la mayoría de los escenarios de segmentación de imágenes médicas, el rendimiento subóptimo de segmentación de SAM no cumple con los requisitos para aplicaciones posteriores, particularmente en algunas tareas que exigen una precisión extremadamente alta. El conjunto de datos SA-1B, los datos de entrenamiento de SAM, está compuesto principalmente por imágenes naturales con información de borde fuerte y presenta una disimilitud significativa con las imágenes médicas. En consecuencia, aplicar SAM directamente sin ajuste fino o reentrenamiento a tareas desafiantes y no vistas previamente en la segmentación de imágenes médicas puede resultar en un rendimiento limitado. Vease [29].

6.3. Adaptando SAM para imágenes médicas.

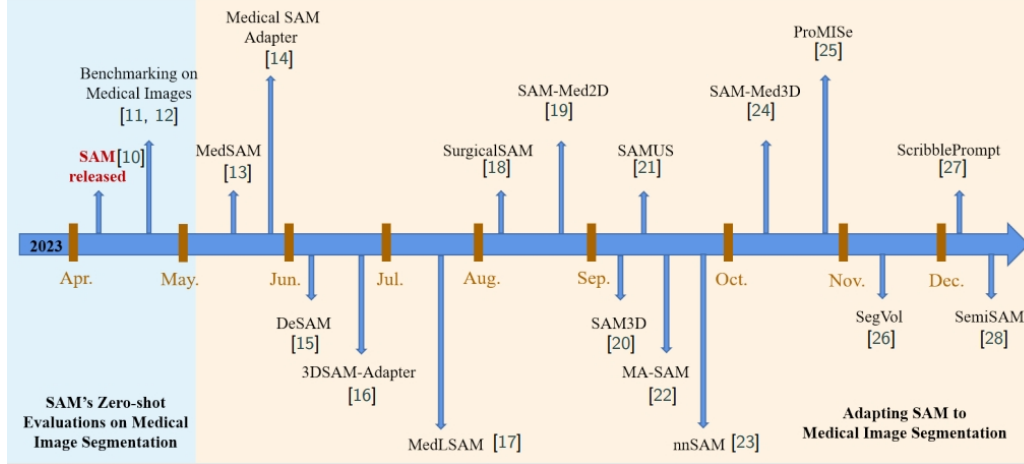
Por estos motivos se han realizado varios estudios con el objetivo de adaptar SAM para mejorar su rendimiento en imágenes médicas. La figura 3 ilustra las diferentes modalidades de SAM a lo largo de los años.

Para mejorar el rendimiento insatisfactorio de SAM en tareas de segmentación de imágenes médicas, un enfoque directo e intuitivo es ajustar finamente SAM con imágenes médicas, lo que incluye tanto el ajuste completo como el ajuste eficiente de parámetros. El enfoque más sencillo para adaptar SAM a la segmentación de imágenes médicas es ajustar finamente SAM directamente en la tarea específica que se tiene entre manos. .

Hu et al. [14] presenta una validación del ajuste fino de SAM para la segmentación de cáncer de piel, demostrando una mejora sustancial en la puntuación DSC, que pasó del 81.25 % al 88.79 % . Vease [29]. MedSAM [18] es un modelo universal para la segmentación de imágenes médicas que se adapta de SAM utilizando un conjunto de datos diverso con más de un millón de pares de imágenes y máscaras de 11 modalidades. Logró puntuaciones medianas de DSC del 94.0 % al 98.4 % en tareas como hemorragia

³State of the Art(Estado del arte), por sus siglas en inglés

Figura 3: Una breve cronología del modelo Segment Anything (SAM) [16] y sus variantes para la segmentación de imágenes médicas en 2023. Imagen adaptada de Zhang et al. [29]



intracraneal, glioma, neumotórax y pólipos, superando a los modelos U-Net especializados. Sin embargo, enfrenta dificultades para segmentar estructuras ramificadas similares a vasos debido a la ambigüedad en los prompts de caja delimitadora y solo procesa imágenes 3D como series de cortes 2D en lugar de volúmenes.

El fine-tuning eficiente en parámetros (PEFT) es un enfoque utilizado para mejorar el rendimiento de modelos de aprendizaje automático, especialmente en el contexto de modelos de lenguaje y redes neuronales. Este método se centra en ajustar solo un pequeño subconjunto de los parámetros del modelo preentrenado, lo que permite adaptar el modelo a tareas específicas sin necesidad de realizar un ajuste completo, que puede ser costoso en términos de recursos computacionales y tiempo. Wu et al. [26] proponen el Adaptador SAM Médico (Med-SA), que mantiene los parámetros preentrenados de SAM congelados mientras integra módulos de adaptación de rango bajo (LoRA) [13] en posiciones designadas. Los extensos experimentos realizados en 17 tareas de segmentación de imágenes médicas a través de 5 modalidades diferentes muestran la superioridad de Med-SA sobre SAM y métodos anteriores de estado del arte (SOTA) [29]. Similarmente SAMed [27] aplica una estrategia de ajuste fino basada en rango bajo (LoRA) al codificador de imágenes

de SAM y lo ajusta junto con el codificador de prompts y el decodificador de máscaras en conjuntos de datos etiquetados para segmentación de imágenes médicas. Además, dado que SAMed solo actualiza una pequeña fracción de los parámetros de SAM, su costo y almacenamiento son bastante marginales en su uso práctico. Existen otro muchos modelos adaptados de SAM como se aprecia en la figura 3

7. Conclusiones

8. Recomendaciones

en la figura 1

9. Bibliografía

- [1] Gretel Garcia Gomez et al. «Características ideales para datasets en segmentación médica: un enfoque práctico». En: (2020). URL: https://www.researchgate.net/publication/336879527_Segmentacion_automatica_de_ulceras_del_pie_diabetico_y_tejidos_internos_mediante_aprendizaje_automatico Automatic_Segmentation_of_Diabetic_Foot_Ulcers_and_Internal_Tissues_with_Machine_Learning.
- [2] Gretel Garcia Gomez et al. «Segmentación automática de úlceras del pie diabético y tejidos internos mediante aprendizaje automático». En: (2019). URL: https://www.researchgate.net/publication/336879527_Segmentacion_automatica_de_ulceras_del_pie_diabetico_y_tejidos_internos_mediante_aprendizaje_automatico Automatic_Segmentation_of_Diabetic_Foot_Ulcers_and_Internal_Tissues_with_Machine_Learning.
- [3] Heber et al. «Mejoramiento de contraste y segmentación en imágenes de úlceras del pie diabético». En: *Revista Angiología* (2019). URL: <https://revangiologia.sld.cu/index.php/ang/article/view/61>.
- [4] Nicolás Pereira C. et al. «Úlceras del pie diabético: importancia del manejo multidisciplinario y salvataje microquirúrgico de la extremidad». En: *Revista Chilena de Cirugía* (2018). URL: <https://www.scielo.cl/pdf/rchcir/v70n6/0718-4026-rchcir-70-06-0535.pdf>.
- [5] Wang et al. «Evaluación cuantitativa de técnicas automáticas para segmentación médica». En: *Journal of Medical Imaging* (2020). URL: https://ejemplo.com/articulo_evaluacion_tecnicas.
- [6] T. Brown et al. «Language models are few-shot learners». En: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 1877-1901.
- [7] Úlceras Cl. *El proceso de cicatrización de las heridas crónicas*. Accedido: diciembre 2024. 2024. URL: <https://ulceras.cl/monografico/el-proceso-de-cicatrizacion-de-las-heridas-cronicas/>.

- [8] Desconocido. «Base de datos sobre úlceras del pie diabético: características y aplicaciones». En: *Revista Cubana Angiología Cirugía Vascular* (2019). URL: <https://pesquisa.bvsalud.org/portal/resource/pt/biblio-1093137>.
- [9] Desconocido. «Tendencias recientes en tecnología médica: aplicaciones móviles en el seguimiento médico». En: *Revista Médica Innovadora* (2021). URL: https://ejemplo.com/articulo_tecnologia_medica.
- [10] International Diabetes Federation. *Diabetes Atlas*. 2024. URL: <https://diabetesatlas.org/> (visitado 09-12-2024).
- [11] Damir Filko, Robert Cupec y Emmanuel Karlo Nyarko. «Wound measurement by RGB-D camera». En: *Machine Vision and Applications* 29 (2018), pp. 633-654. DOI: 10.1007/s00138-018-0920-4.
- [12] Damir Filko y Emmanuel Karlo Nyarko. «2D/3D Wound Segmentation and Measurement Based on a Robot-Driven Reconstruction System». En: *Sensors* 23.6 (2023), p. 3298. DOI: 10.3390/s23063298.
- [13] E. J. Hu et al. «LoRA: Low-Rank Adaptation of Large Language Models». En: *arXiv preprint arXiv:2106.09685* (2021). URL: <https://arxiv.org/abs/2106.09685>.
- [14] M. Hu, Y. Li y X. Yang. «Skinsam: Empowering skin cancer segmentation with segment anything model». En: *arXiv preprint arXiv:2304.13973* (2023). URL: <http://arxiv.org/abs/2304.13973>.
- [15] Yuhao Huang et al. «Segment Anything Model for Medical Images». En: *arXiv preprint arXiv:2408.00874* (2024). URL: <https://arxiv.org/abs/2408.00874>.
- [16] A. Kirillov et al. «Segment anything». En: *arXiv preprint arXiv:2304.02643* (2023).
- [17] Tsung-Yi Lin et al. «Focal Loss for Dense Object Detection». En: *2017 IEEE International Conference on Computer Vision (ICCV)*. IEEE. 2017, pp. 2999-3007.
- [18] Jun Ma y Bo Wang. «Segment anything in medical images». En: *arXiv preprint arXiv:2304.12306* (2023).
- [19] Jun Ma et al. «Segment Anything in Medical Images». En: *arXiv preprint arXiv:2304.12306* (2023). URL: <https://arxiv.org/abs/2304.12306>.

- [20] Meta AI. *Segment Anything*. Accedido el 14 Nov 2024. 2023. URL: <https://segment-anything.com/>.
- [21] Fausto Milletari, Nassir Navab y Seyed-Ahmad Ahmadi. «V-net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation». En: *2016 Fourth International Conference on 3D Vision (3DV)*. IEEE. 2016, pp. 565-571.
- [22] Ministerio de Salud Pública. *Anuario Estadístico de Salud 2022*. Accedido el 14 Nov 2024. La Habana: Dirección Nacional de Registros Médicos y Estadísticas de Salud. 2023. URL: <https://salud.msp.gob.cu/wp-content/Anuario/Anuario-2022.pdf>.
- [23] Clínica Universidad de Navarra. *Tejido de granulación*. Accedido: diciembre 2024. 2023. URL: <https://www.cun.es/diccionario-medico/terminos/tejido-de-granulacion>.
- [24] OpenAI. «GPT-4 Technical Report». En: *arXiv preprint arXiv:2303.08774* (2023). URL: <https://arxiv.org/abs/2303.08774>.
- [25] Maithra Raghu et al. «Transfusion: Understanding Transfer Learning for Medical Imaging». En: *Advances in Neural Information Processing Systems*. Vol. 32. 2019. URL: <https://www.semanticscholar.org/paper/Transfusion:-Understanding-Transfer-Learning-for-Raghu-Zhang/cff4cb74f4466bd0407977e40ef0be9f444c63ea>.
- [26] J. Wu et al. «Medical SAM Adapter: Adapting Segment Anything Model for Medical Image Segmentation». En: *arXiv preprint arXiv:2304.12620* (2023). URL: <https://arxiv.org/abs/2304.12620>.
- [27] K. Zhang y D. Liu. «Customized Segment Anything Model for Medical Image Segmentation». En: *arXiv preprint arXiv:2304.13785* (2023). URL: <https://arxiv.org/abs/2304.13785>.
- [28] Peng Zhang, Yichen Zhang y Qiang Li. «RGB-D Camera-Based Automatic Wound-Measurement System». En: *IEEE Transactions on Instrumentation and Measurement* (2023).
- [29] Yichi Zhang, Zhenrong Shen y Rushi Jiao. «Segment Anything Model for Medical Image Segmentation: Current Applications and Future Directions». En: *arXiv* (2024). URL: <https://arxiv.org/abs/2401.03495>.

10. Anexos